



Promotor: mgr Beata Zalewa
Rok akademicki 2025/2026

UNIWERSYTET WSB MERITO WROCŁAW
Studia podyplomowe

**„ANALIZA BEZPIECZEŃSTWA MODELI SZTUCZNEJ
INTELIGENCJI W KONTEKŚCIE ATAKÓW
ADWERSARIALNYCH ORAZ PORÓWNANIE NARZĘDZI IBM
ADVERSARIAL ROBUSTNESS TOOLBOX (ART) I FOOLBOX”**

Studia podyplomowe na kierunku:
CyberAI: zintegrowane bezpieczeństwo i sztuczna inteligencja

Autor: Student
Nr albumu: XXXXX

Wrocław, 2026

SPIS TREŚCI

1. Wstęp	1
1.1 Wprowadzenie do AI w systemach IT	1
1.2 Znaczenie bezpieczeństwa modeli AI – dlaczego odporność na ataki jest kluczowa	2
1.3 Zagrożenia dla AI	3
1.3.1 Ataki adversarialne	3
1.3.2 Data poisoning	3
1.3.3 Model extraction.....	4
1.4 Cel pracy	4
2. Aspekty prawne i regulacyjne	5
2.1 Odpowiedzialność za decyzje AI	5
2.2 Najważniejsze przepisy: AI Act, RODO	6
2.3 Znaczenie audytów bezpieczeństwa i zgodności z prawem	8
3. Narzędzia	11
3.1 IBM ART – funkcje, zalety, wady	11
3.2 Foolbox – funkcje, zalety, wady	12
4. Podstawy teoretyczne	15
4.1 Czym jest ML (Machine Learning) i DL (Deep Learning)	15
4.2 Rodzaje modeli: konwolucyjne sieci neuronowe (CNN) oraz klasyczne modele uczenia maszynowego (drzewa decyzyjne).....	15
4.3 Adversarialne ataki na modele uczenia maszynowego: FGSM, PGD, CW	16
4.4 White-box, black-box i gray-box	17
5. Implementacja	18
5.1 Środowisko implementacyjne (Python, PyTorch, IBM Adversarial Robustness Toolbox (ART), Foolbox)	18
5.2 Modele i dane	19
5.3 Implementacja ataków FGSM	21
5.3.1 FGSM – IBM ART	21
5.3.2 FGSM – Foolbox	21
5.4 Procedura testowa	23

6. Wyniki	24
6.1 Tabela wyników: accuracy przed i po ataku, attack success rate	24
6.2 Analiza wyników	27
6.3 Porównanie accuracy modelu przed i po ataku (ART i Foolbox)	27
7. Analiza wyników	31
7.1 Ograniczenia eksperymentu	31
7.2 Interpretacja wyników i kontekst narzędzi	31
7.3 Wnioski z eksperymentu i obserwacji	32
8. Rekomendacje używania narzędzi	33
8.1 Kiedy stosować ART, kiedy Foolbox	33
8.2 Tabela porównawcza narzędzi	33
9. Wnioski	35
9.1 Podsumowanie wyników i obserwacji	35
9.2 Wnioski ogólne	35
9.3 Ograniczenia i dalsze prace	35
10. Bibliografia	36
11. Spisy	39
11.1 Spis rysunków	39
11.2 Spis tabel	40
11.3 Spis listingów	40

1. Wstęp

1.1 Wprowadzenie do AI w systemach IT

Inteligencja, wywodząca się z łacińskiego słowa *intelligentia*, odnosi się m.in. do zdolności przyswajania wiedzy oraz rozumienia otoczenia. Stanowi ona jedną z kluczowych cech człowieka (*Homo sapiens*), umożliwiając adaptację do zmieniających się warunków środowiskowych.

Sztuczna inteligencja (*ang. Artificial Intelligence, AI*) stanowi dziedzinę nauki i inżynierii, której celem jest zarówno analiza procesów poznawczych, jak i tworzenie systemów zdolnych do naśladowania ludzkiego myślenia oraz podejmowania decyzji¹.

Istotnym aspektem rozumienia sztucznej inteligencji jest sposób, w jaki ocenia się jej zdolność do naśladowania ludzkiego zachowania. Jednym z najbardziej znanych podejść jest test Turinga², zaproponowany w 1950 roku przez Alana Turinga, brytyjskiego matematyka i informatyka, uznawanego za jednego z pionierów sztucznej inteligencji. Test polega na przeprowadzeniu konwersacji tekstowej pomiędzy człowiekiem a maszyną, przy udziale sędziego, którego zadaniem jest określenie, czy rozmówcą jest człowiek, czy system komputerowy. Celem tego podejścia jest sprawdzenie, czy maszyna potrafi naśladować ludzkie zachowanie w stopniu uniemożliwiającym jednoznaczne odróżnienie jej od człowieka. Jest to wymagający proces, który rzadko przynosi jednoznaczne wyniki. Jego istotą jest ocena, czy system potrafi prowadzić rozmowę w sposób zbliżony do człowieka oraz - podobnie jak człowiek - wyciągać wnioski z przebiegu dialogu.

Początki tej dziedziny sięgają okresu po II wojnie światowej, natomiast sam termin „sztuczna inteligencja” został wprowadzony przez Johna McCarthy’ego w 1956 roku podczas konferencji w Darmouth.

Sztuczna inteligencja obejmuje szeroki zakres zagadnień, od ogólnych procesów takich jak uczenie się i dedukcja, po konkretne zastosowania, takie jak gra w szachy, rozwiązywanie problemów matematycznych czy wspomaganie diagnostyki medycznej. Z tego względu AI jest dziedziną o charakterze wszechstronnym, znajdująca

¹ S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed., Pearson, 2009.

² „Test Turinga – sztuczna inteligencja”, Infor.pl, <https://ai.infor.pl/sztuczna-inteligencja/5757751,test-turinga-ai.html>, (dostęp: 28.04.2026).

zastosowanie w wielu obszarach obecnych systemów informatycznych³.

Jej dynamiczny rozwój sprawia, że jest wykorzystywana w licznych sektorach gospodarki i technologii, m.in. w bankowości, systemach bezpieczeństwa oraz przemyśle IT.

1.2 Znaczenie bezpieczeństwa modeli AI – dlaczego odporność na ataki jest kluczowa

Sztuczna inteligencja wiąże się również z kwestiami bezpieczeństwa. Wiarygodność (*ang. trustworthiness*) jest bardzo ważną cechą, którą należy podkreślać mówiąc o sztucznej inteligencji. W dokumencie *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*⁴ wskazuje się, że bezpieczeństwo oraz wiarygodność są jednymi z fundamentalnych cech systemów sztucznej inteligencji. Jeżeli system sztucznej inteligencji jest uznany za bezpieczny dla człowieka, zmniejsza to ryzyko związane z jego wykorzystaniem. Przy analizie cech związanych z wiarygodnością systemów sztucznej inteligencji istotne jest uwzględnienie czynnika ludzkiego, który odgrywa kluczową rolę w ocenie i wykorzystaniu takich systemów. Dlatego ważne jest, aby analizować te cechy łącznie, a nie każdą z osobna, ponieważ dopiero ich wspólne uwzględnienie pozwala na pełną ocenę systemu sztucznej inteligencji.

Wiarygodność systemów AI ma charakter społeczno-techniczny i jest uzależniona od modelu, danych oraz interakcji z interesariuszami. Niekiedy w systemach sztucznej inteligencji występują kompromisy pomiędzy różnymi właściwościami. Przykładowo, zwiększenie poziomu ochrony danych osobowych oraz zastosowanie technik zwiększających prywatność może prowadzić do obniżenia dokładności modeli. Analiza takich zależności nie dostarcza jednoznacznych odpowiedzi dotyczących sposobu ich rozwiązania. W związku z tym istnieją różne punkty widzenia na działanie systemów sztucznej inteligencji, co oznacza, że ich ocena może się różnić w zależności od interesariuszy oraz celu zastosowania systemu.

³ Instytut Badań Edukacyjnych, „Sztuczna inteligencja (AI) jako megatrend kształtujący edukację”, <https://kwalifikacje.edu.pl/wp-content/uploads/Sztuczna-inteligencja-jako-megatrend-ksztaltujacy-edukacje.pdf>, (dostęp: 10.05.2026).

⁴ National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1, 2023, <https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf> (dostęp: 28.04.2026).

1.3 Zagrożenia dla AI

Należy wyróżnić zagrożenia, które mogą zaburzać funkcjonowanie modeli uczenia maszynowego oraz wpływać na poprawność ich działania.

Do najważniejszych z nich należą ataki adversarialne (*ang. adversarial attacks*), zatrutowanie danych (*ang. data poisoning*) oraz ekstrakcja modeli (*ang. model extraction*).

1.3.1 Ataki adversarialne

Ataki adversarialne (*ang. adversarial attacks*) to technika polegająca na wprowadzaniu niewielkich zmian w danych wejściowych, które są trudne do zauważenia dla człowieka, lecz mogą prowadzić do błędnych decyzji modeli uczenia maszynowego. Celem takich działań jest ich „oszukanie” i spowodowanie nieprawidłowych wyników działania. W wyniku takich manipulacji algorytmy sztucznej inteligencji mogą dokonywać nieprawidłowych klasyfikacji, mimo, że dane wejściowe pozostają niezmienione w percepcji człowieka⁵.

Przykładem może być sytuacja, w której niewielka zmiana pikseli w obrazie kota powoduje, że model klasyfikuje go jako inną kategorię, np. psa.

Oprócz obrazów, ataki adversarialne występują również w systemach przetwarzania tekstu, mowy oraz w systemach bezpieczeństwa, w tym w rozwiązaniach opartych na sztucznej inteligencji stosowanych w filtrach antyspamowych czy wykrywaniu fałszywych wiadomości. Wzrost liczby takich ataków może prowadzić do błędów w działaniu systemów bezpieczeństwa oraz obniżenia ich wiarygodności. W zastosowaniach praktycznych może to skutkować znacznymi stratami finansowymi oraz naruszeniami danych osobowych. Ma to szczególne znaczenie w kontekście regulacji takich jak RODO⁶.

1.3.2 Data poisoning

Zatrutowanie danych treningowych (*ang. data poisoning*) to rodzaj cyberataku, którego celem jest wprowadzenie w błąd modeli uczenia maszynowego. Osoba atakująca celowo wprowadza do zbioru treningowego nieprawidłowe lub zmanipulowane dane, co skutkuje zakłóceniem procesu uczenia modelu.

⁵ becyber.pl, *Ataki adversarialne na AI – co to jest i jak się chronić*, <https://becyber.pl/ataki-adversarialne-na-ai-co-to-jest-i-jak-sie-chronic/> (dostęp: 28.04.2026).

⁶ Gov.pl, *Baza wiedzy - Zagrożenia dla systemów wykorzystujących AI*, <https://www.gov.pl/web/baza-wiedzy/zagrozenia-dla-systemow-wykorzystujacych-ai> (dostęp: 28.04.2026).

Istotne jest, że dane wykorzystywane przez modele sztucznej inteligencji często są pozyskiwane z niezawerowanych źródeł, np. z internetu. Oznacza to, że obrazy, teksty lub inne dane przygotowane przez osoby trzecie (np. cyberprzestępców) mogą zostać nieświadomie włączone do zbioru treningowego. Już na etapie uczenia może to negatywnie wpływać na działanie modelu oraz jego zdolność do prawidłowego rozpoznawania wzorców.

Data poisoning jest trudne do zidentyfikowania, ponieważ zmanipulowane dane stanowią jedynie niewielki fragment całego zbioru danych.

W rezultacie nawet zaawansowane modele sztucznej inteligencji mogą być podatne na zatrucie danych⁷.

1.3.3 Model extraction

Ekstrakcja modelu AI (*ang. model extraction*) to rodzaj ataku, w którym atakujący odpytuje docelowy model w celu pozyskania jego odpowiedzi i wykorzystania ich do wytrenowania modelu zastępczego. Metoda ta koncentruje się przede wszystkim na odtworzeniu funkcjonalności modelu. Celem osoby atakującej jest analiza zachowania modelu w odpowiedzi na określone dane wejściowe, co prowadzi do stworzenia kopii, która imituje działanie oryginalnego modelu⁸.

1.4 Cel pracy

Celem niniejszej pracy jest porównanie narzędzi IBM Adversarial Robustness Toolbox (ART) oraz Foolbox w kontekście analizy odporności modeli uczenia maszynowego na wybrane ataki adversarialne.

Praca zawiera implementację oraz analizę wybranych metod ataków. Porównano również efektywność obu narzędzi podczas testów praktycznych.

⁷ LayerX Security, *Data Poisoning in AI Systems*, <https://layerxsecurity.com/pl/generative-ai/data-poisoning/> (dostęp: 28.04.2026).

⁸ Brian D. Colwell, *An Introduction to AI Model Extraction*, <https://briandcolwell.com/an-introduction-to-ai-model-extraction/> (dostęp: 28.04.2026).

2. Aspekty prawne i regulacje

2.1 Odpowiedzialność za decyzje AI

Systemy sztucznej inteligencji (*ang. Artificial Intelligence, AI*) coraz śmielej wkraczają do codziennego życia, wspierając podejmowanie decyzji, rozwiązywanie problemów i automatyzację procesów, które jeszcze niedawno wymagały wyłącznie ludzkiej pracy. Dzięki technikom takim jak sieci neuronowe, inteligentne maszyny potrafią analizować ogromne ilości danych, przewidywać trendy, a nawet tworzyć nowe rozwiązania, które zmieniają każdego z nas, a także społeczeństwo, sposób funkcjonowania firm i organizacji, gospodarkę, medycynę, finanse, transport, film, reklamę i wiele innych dziedzin życia codziennego⁹. Wykorzystywanie sztucznej inteligencji pozwala również na zwiększenie efektywności, optymalizację kosztów i tworzenie produktów lepiej dopasowanych do potrzeb konsumentów.

Nie można też zapominać o sztucznej inteligencji w kontekście poszanowania praw i wolności człowieka, relacji międzyludzkich i rynku pracy. Automatyzacja procesów może bowiem prowadzić do zaniku niektórych zawodów, co rodzi pytania o przyszłość zatrudnienia i konieczność przekwalifikowania pracowników na nowym rynku pracy.

Sztuczna inteligencja znajduje szerokie zastosowanie w codziennym życiu, m.in. w systemach rekomendacyjnych oraz wspomaganiu diagnozy medycznej. AI to potężne narzędzie, ale jak każde narzędzie, może być używane w różny sposób. Kluczowe cechy AI, takie jak rozumienie języka, rozpoznawanie obrazów czy zdolność do uczenia się, sprawiają, że narzędzia te są coraz bardziej zaawansowane, ale jednocześnie wymagają szczególnej kontroli.

Właśnie w tym momencie zaufanie do technologii zderza się z realnym ryzykiem. Na skutek takich właśnie powodów pojawia się pytanie: kto zatem odpowiada za decyzje podjęte przez AI - producent, użytkownik, a może algorytm? Idąc głębiej w tej analizie, należy się zastanowić, czy sztuczna inteligencja może ponosić odpowiedzialność prawną? W Polsce, co do zasady, podmiotowość prawną przyznaje się osobom prawnym oraz osobom fizycznym, natomiast sztuczna inteligencja, jako system maszynowy posiadający określone cechy, nie ma osobowości prawnej, co uniemożliwia pociągnięcie

⁹ Gov.pl, Ministerstwo Cyfryzacji, *Koniec ery nieuchwytnych algorytmów – projekt ustawy o systemach sztucznej inteligencji przyjęty przez Radę Ministrów*, <https://www.gov.pl/web/cyfryzacja/koniec-ery-nieuchwytnych-algorytmow--projekt-ustawy-o-systemach-sztucznej-inteligencji-przyjety-przez-rade-ministrow> (dostęp: 28.04.2026).

jej do odpowiedzialności cywilnej. Tak więc, kto ponosi odpowiedzialność za jej działanie lub zaniechanie?

Sztuczna inteligencja nie działa samodzielnie, dlatego odpowiedzialność za jej działanie wynika przede wszystkim z ogólnych przepisów prawa cywilnego. Regulacje takie jak AI Act (Akt o Sztucznej Inteligencji) oraz RODO (Rozporządzenie o Ochronie Danych Osobowych) określają natomiast obowiązki podmiotów wykorzystujących systemy AI, a ich naruszenie może prowadzić do sankcji administracyjnych¹⁰.

2.2 Najważniejsze przepisy: AI Act, RODO

Rozwój sztucznej inteligencji rodzi wyzwania prawne. Coraz więcej organizacji musi mierzyć się z kwestią zgodności (*ang. compliance*), czyli zapewnienia zgodności działań z obowiązującym prawem i regulacjami. W Polsce, podobnie jak w innych krajach, istnieje potrzeba ukształtowania jasnych ram prawnych, które pozwolą na bezpieczne i odpowiedzialne wykorzystywanie sztucznej inteligencji.

Na dzień dzisiejszy podstawowym przepisem jest Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (potocznie nazywane RODO)¹¹ oraz uchylecia dyrektywy 95/46/WE (ogólne rozporządzenie o ochronie danych). W Polsce uzupełnia je Ustawa z dnia 10 maja 2018 roku o ochronie danych osobowych (Dz.U.2019.1781 t.j.)¹².

Natomiast w 2024 roku uzupełnieniem ram regulacyjnych zostało Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 roku w sprawie ustanowienia zharmonizowanych przepisów dotyczących sztucznej inteligencji oraz zmiany rozporządzeń (WE) nr 300/2008, (UE) nr 167/2013, (UE) nr 168/2013, (UE) 2018/858, (UE) 2018/1139 i (UE) 2019/2144 oraz dyrektyw 2014/90/UE, (UE) 2016/797 i (UE) 2020/1828 (akt w sprawie sztucznej inteligencji)¹³, tekst mający znaczenie dla EOG – Europejskiego Obszaru Gospodarczego. Rozporządzenie weszło w życie

¹⁰ UODO, Urząd Ochrony Danych Osobowych – strona główna, <https://uodo.gov.pl/pl> (dostęp: 28.04.2026).

¹¹ SIP Lex, RODO – Rozporządzenie 2016/679, <https://sip.lex.pl/akty-prawne/dzienniki-UE/rozporzadzenie-2016-679-w-sprawie-ochrony-osob-fizycznych-w-zwiazku-z-68636690> (dostęp: 28.04.2026).

¹² ISAP, Ustawa o ochronie danych osobowych, <https://isap.sejm.gov.pl/isap.nsf/DocDetails.xsp?id=WDU20150001480> (dostęp: 28.04.2026).

¹³ Ministerstwo Cyfryzacji, Europejski AI Act opublikowany, <https://www.gov.pl/web/cyfryzacja/europejski-ai-act-opublikowany> (dostęp: 28.04.2026).

1 sierpnia 2024 roku , a poszczególne jego przepisy zaczęły lub zaczną obowiązywać etapami:

- 2 lutego 2025 roku - zakaz niedopuszczalnych praktyk AI (art. 5) oraz obowiązki dotyczące kompetencji w zakresie AI (*ang. AI literacy*, art. 4).
- 2 sierpnia 2025 roku - przepisy dotyczące modeli AI ogólnego przeznaczenia (*ang. General Purpose AI, GPAI*), w tym obowiązki dla dostawców dużych modeli językowych (*ang. Large Language Models, LLMs*).
- 2 sierpnia 2026 roku - pełne stosowanie przepisów dotyczących systemów AI wysokiego ryzyka z Załącznika III (m.in. rekrutacja, *scoring*, edukacja, wymiar sprawiedliwości) plus obowiązki przejrzystości dla systemów ograniczonego ryzyka.
- 2 sierpnia 2027 roku - przepisy dotyczące systemów AI wysokiego ryzyka wbudowanych w produkty regulowane (np. urządzenia medyczne, pojazdy, maszyny).

AI Act wprowadza podejście oparte na analizie ryzyka, klasyfikując systemy sztucznej inteligencji na cztery kategorie: systemy o niedopuszczalnym ryzyku, wysokiego ryzyka, ograniczonego ryzyka oraz minimalnego ryzyka. W Polsce prowadzone są również działania mające na celu dostosowanie krajowego porządku prawnego do przepisów AI Act.

W dniu 31 marca 2026 roku Rada Ministrów przyjęła projekt ustawy o systemach sztucznej inteligencji, mający na celu dostosowanie krajowego porządku prawnego do przepisów AI Act. Przepisy ustawy o systemach sztucznej inteligencji mają wzmacniać bezpieczeństwo obywateli i ustanawiać skuteczny nadzór nad AI, a dla przedsiębiorców mają tworzyć stabilne i sprzyjające warunki do rozwoju innowacji. Ustawa ma zapewnić stosowanie przepisów unijnego rozporządzenia AI Act w polskim porządku prawnym.

RODO koncentruje się na ochronie danych osobowych i zapewnia, że dane takie jak imię, nazwisko czy adres są przetwarzane w sposób bezpieczny i transparentny. Ale RODO nie było stworzone z myślą o złożonościach systemów AI. Warto podkreślić, że funkcje AI obejmują nie tylko analizę danych, ale także przetwarzanie informacji i personalizację usług, co wymaga szczególnej uwagi w kontekście ochrony prywatności. RODO określa zasady przetwarzania danych. Mówi o prawie do dostępu do swoich danych i ich sprostowania. W kontekście sztucznej inteligencji, RODO nakazuje, aby wszelkie dane, na których trenowane są algorytmy, były pozyskiwane legalnie, a całe

przetwarzanie odbywało się z zachowaniem zasad minimalizacji i bezpieczeństwa. Zadaniem podmiotów w celu zapewnienia zgodności z RODO jest m.in. wdrażanie odpowiednich polityk, procedur oraz regularne audyty.

AI Act nie skupia się na danych samych w sobie, ale na sposobie, w jaki systemy AI je wykorzystują oraz w jaki sposób podejmują decyzje¹⁴. Wprowadza reguły dla samej technologii, kategoryzując systemy pod względem ryzyka, jakie stwarzają. Zakazuje najbardziej szkodliwych praktyk, a dla systemów wysokiego ryzyka nakłada szereg obowiązków dotyczących ich projektowania, dokumentacji, przejrzystości oraz nadzoru człowieka.

W realizacji wymogów zgodności (*ang. compliance*), kluczową rolę odgrywają także partnerzy biznesowi, którzy wspierają przedsiębiorstwo w zakresie przetwarzania danych, wdrażania rozwiązań AI oraz zapewnienia zgodności z regulacjami. Tak więc oba rozporządzenia obowiązują jednocześnie. Jeśli system AI, który przetwarza dane osobowe, narusza prawa wynikające z RODO i jednocześnie nie spełnia wymogów AI Act, podlega karom wynikającym z obu regulacji. W 2026 roku, zwłaszcza po wejściu w życie kluczowych przepisów AI Act, żadna firma wykorzystująca AI nie może pozwolić sobie na ignorowanie któregośkolwiek z tych rozporządzeń. Te dwa akty prawne nie stanowią alternatywy, lecz wzajemnie uzupełniające się filary. Ich misja jest wspólna - ochrona praw i wolności obywateli coraz bardziej zdominowanych przez algorytmy.

2.3 Znaczenie audytów bezpieczeństwa i zgodności z prawem

Audyt to nie tylko kontrola dokumentów czy analiza procedur. To przede wszystkim proces kompleksowej weryfikacji, która pozwala ocenić, czy działalność organizacji lub instytucji przebiega zgodnie z obowiązującym prawem, normami branżowymi oraz wewnętrznymi regulacjami¹⁵. W dużych spółkach, gdzie liczba procesów, umów i interakcji z otoczeniem regulacyjnym jest ogromna, audyt pełni funkcję systemowego zabezpieczenia przed błędami, niedopatrzzeniami i potencjalnymi naruszeniami.

Audyt wykonują wyspecjalizowane firmy oraz przygotowani do tego audytorzy, którzy w swoim działaniu muszą kierować się zasadami: rzetelności, uczciwości, zgodności z etyką, należytej staranności, niezależności, poufności i wnioskowaniu w

¹⁴ Ministerstwo Cyfryzacji, *Europejski AI Act opublikowany*, <https://www.gov.pl/web/cyfryzacja/europejski-ai-act-opublikowany> (dostęp: 28.04.2026).

¹⁵ PUW, *Czym jest audyt*, <https://www.puw.pl/strefa-wiedzy/czym-jest-audyt-rodzaje-metody-i-cele-jego-przeprowadzania> (dostęp: 28.04.2026).

oparciu o konkretne dowody. Badają oni m.in. zgodność z przepisami podatkowymi, przepisami prawa pracy, ochrony środowiska, ochrony danych osobowych (RODO), oceny ryzyka rozwiązań AI, regulacjami sektorowymi (np. finansowymi czy energetycznymi) oraz standardami korporacyjnymi. Jednym z kryteriów podziału audytów jest podmiot, który je przeprowadza. W tym zakresie wyróżnia się trzy podstawowe rodzaje audytowania: audyt wewnętrzny, audyt zewnętrzny oraz audyt trzeciej strony. Podstawa prawna przeprowadzenia audytu zależy od jego rodzaju, np. finansowego, wewnętrznego, RODO, AI oraz sektora, w jakim działa organizacja.

W przypadku audytu finansowego (badanie sprawozdań finansowych) podstawę stanowi Ustawa z dnia 29 września 1994 roku o rachunkowości (t.j.Dz.U.2023.120) oraz Ustawa z dnia 11 maja 2017 roku o biegłych rewidentach^{16, 17}, firmach audytorskich oraz nadzorze publicznym (t.j.Dz. U. z 2022.1302), która reguluje zasady przeprowadzania audytu przez biegłych.

Jeżeli chodzi o audyt wewnętrzny w sektorze finansów publicznych, podstawę stanowi Ustawa z dnia 27 sierpnia 2009 r. o finansach publicznych (t.j. Dz.U.2025.1483) oraz Rozporządzenie Ministra Finansów z dnia 4 września 2015 roku w sprawie szczegółowego sposobu i trybu przeprowadzania audytu wewnętrznego (t.j. Dz.U.2018.506), które określa procedury^{18, 19}.

Audyt zgodności z przepisami (np. RODO, AI) przeprowadza się zgodnie z RODO, które stanowi podstawę dla audytów zgodności z ochroną danych osobowych, często określanych jako audyt RODO. Natomiast audyt AI opiera się głównie na połączeniu nowych regulacji unijnych z przepisami o ochronie danych osobowych RODO, gdzie audyt AI często obejmuje ocenę skutków dla ochrony danych, szczególnie, gdy AI służy do profilowania pracowników lub klientów²⁰. Audyt systemów AI opiera się na AI Act, zwłaszcza w zakresie przepisów obowiązujących od 2 lutego 2025 roku, gdzie dla

¹⁶ SIP Lex, Ustawa o rachunkowości, <https://sip.lex.pl/akty-prawne/dzu-dziennik-ustaw/rachunkowosc-16796295> (dostęp: 28.04.2026).

¹⁷ PIBR, Ustawa o biegłych rewidentach, <https://www.pibr.org.pl/pl/aktualnosci/1801,Tekst-jednolity-ustawy-o-bieglych-rewidentach> (dostęp: 28.04.2026).

¹⁸ Ministerstwo Finansów, Akty prawne – audyt wewnętrzny, <https://www.gov.pl/web/finanse/akty-prawne-audit-wewnetrzny> (dostęp: 28.04.2026).

¹⁹ Gofin, Rozporządzenie Ministra Finansów 2015, <https://przepisy.gofin.pl/przepisy,4,197,202,3313,,20180309,rozporzadzenie-ministra-finansow-z-dnia-4092015-r-w-sprawie.html> (dostęp: 28.04.2026).

²⁰ SIP Lex, *AI Act – Rozporządzenie UE 2024/1689*, <https://sip.lex.pl/akty-prawne/dzienniki-UE/rozporzadzenie-2024-1689-w-sprawie-ustanowienia-zharmonizowanych-przepisow-72359064> (dostęp: 28.04.2026).

systemów AI wysokiego ryzyka (np. w rekrutacji, edukacji, infrastrukturze krytycznej czy wymiarze sprawiedliwości) audyt zgodności jest wymogiem prawnym.

W przypadku audytu RODO i AI istotne są również prawa autorskie i cywilne, ponieważ audyt sprawdza, czy modele AI nie naruszają tych praw oraz kto ponosi odpowiedzialność za błędne decyzje podejmowane przez systemy. W praktyce audyty te są często elementem systemów zarządzania ryzykiem w organizacjach wykorzystujących sztuczną inteligencję. W przypadku przeprowadzanie audytów AI zajmują się tym wyspecjalizowane firmy doradcze, w tym Deloitte, PricewaterhouseCoopers (PwC), EY (dawniej Ernst & Young), KPMG International, należące do tzw. wielkiej czwórki firm audytorskich²¹.

Przeprowadzenie audytu pozwala firmie zapewnić, że stosowane systemy SI są zgodne z przepisami AI Act, co minimalizuje ryzyko nałożenia kar finansowych i prawnych. Wczesna identyfikacja potencjalnych naruszeń pozwala na ich szybką korektę, unikając tym samym negatywnych skutków prawnych i wizerunkowych.

Dodatkowo audyt pozwala na zidentyfikowanie potencjalnych zagrożeń związanych z działaniem systemów AI (np. technologicznego *biasu* czy nieprawidłowego przetwarzania danych). Dzięki temu można wdrożyć odpowiednie mechanizmy zarządzania ryzykiem, co pomaga zapobiegać kosztownym problemom operacyjnym, finansowym lub wizerunkowym.

Audyt ryzyka umożliwia optymalizację systemów SI pod kątem ich zgodności, wydajności i bezpieczeństwa²². Dzięki temu firma może wykryć luki lub błędy w działaniu algorytmów, co pozwala na ich naprawę i dalszą poprawę działania, przekładając się na większą efektywność operacyjną i lepsze wyniki biznesowe.

Audyt zgodny z AI Act pomaga firmie upewnić się, że stosowane systemy AI nie wprowadzają dyskryminacji i są zgodne z prawami człowieka²³. Ochrona praw użytkowników minimalizuje ryzyko sporów prawnych, utraty klientów oraz strat wizerunkowych wynikających z działań systemów AI, które mogłyby prowadzić do naruszeń prywatności lub nierównego traktowania.

²¹ Prawo.pl, Audyt wewnętrzny może być przeprowadzony przez audytora, <https://www.prawo.pl/samorzad/audyt-wewnetrzny-moze-byc-przeprowadzony-przez-audytora,108951.html> (dostęp: 28.04.2026).


²² PUW, *Czym jest audyt*, <https://www.puw.pl/strefa-wiedzy/czym-jest-audit-rodzaje-metody-i-cele-jego-przeprowadzania> (dostęp: 28.04.2026).

²³ SIP Lex, *AI Act – Rozporządzenie UE 2024/1689*, <https://sip.lex.pl/akty-prawne/dzienniki-UE/rozporzadzenie-2024-1689-w-sprawie-ustanowienia-zharmonizowanych-przepisow-72359064> (dostęp: 28.04.2026).

3. Narzędzia

3.1 IBM ART – funkcje, zalety, wady

IBM Adversarial Robustness Toolbox (ART) jest biblioteką Pythona wykorzystywaną w obszarze bezpieczeństwa uczenia maszynowego (Machine Learning Security). Jej głównym zastosowaniem jest ocena odporności modeli na ataki adversarialne.



Rysunek 1. Wizualizacja zastosowania narzędzia IBM Adversarial Robustness Toolbox (ART) w kontekście współpracy zespołów Red Team i Blue Team.

Źródło: IBM, Adversarial Robustness Toolbox, GitHub, <https://github.com/Trusted-AI/adversarial-robustness-toolbox> (dostęp: 28.04.2026).

Rysunek ilustruje dwa podejścia: Red Team i Blue Team przy wykorzystaniu narzędzia ART. Część czerwona pokazuje sposób analizy ataków na modele uczenia maszynowego, takich jak evasion i extraction, wraz z oceną ich skuteczności (evaluation). Natomiast część niebieska obrazuje mechanizmy obronne, w tym wykrywanie zatrutowania danych (poison detection), ataków typu evasion, a także zastosowanie uczenia adversarialnego (adversarial training) oraz procesy certyfikacji i weryfikacji modeli (certification and verification)²⁴.

Na bazie przedstawionej wizualizacji mechanizmów działania ART można wyróżnić jego główne funkcje, rozszerzone o wnioski z przeprowadzonych eksperymentów.

²⁴ IBM, *Adversarial Robustness Toolbox*, GitHub, <https://github.com/Trusted-AI/adversarial-robustness-toolbox> (dostęp: 28.04.2026).

ART jest narzędziem o charakterze wszechstronnym, cechującym się dużą wielozadaniowością oraz rozbudowaną funkcjonalnością. Obejmuje ono zadania związane z uczeniem maszynowym, takie jak klasyfikacja oraz regresja. Zapewnia również obsługę zróżnicowanych typów danych, w tym obrazów, audio, wideo oraz danych tabelarycznych. Dodatkowo narzędzie umożliwia symulację ataków typu white-box i black-box, co pozwala na analizę zachowania modeli²⁵.

Na podstawie przedstawionych funkcji można wskazać także zalety i wady narzędzia ART, uzupełnione o dodatkowe obserwacje.

Zalety	Wady
Szeroka kompatybilność z wieloma frameworkami uczenia maszynowego.	Stosunkowo wysoki próg wejścia dla osób rozpoczynających pracę z narzędziem.
Zaawansowana ewaluacja modeli.	Środowisko o podwyższonym poziomie trudności.
Obsługa wielu typów ataków adversarialnych.	Konieczność samodzielnego ustawienia poszczególnych opcji.

Tabela 1. Zalety i wady IBM Adversarial Robustness Toolbox (ART).


3.2 Foolbox – funkcje, zalety, wady

Foolbox jest biblioteką Pythona umożliwiającą testowanie odporności modeli uczenia maszynowego, w szczególności sieci neuronowych, na ataki adversarialne. Został on zbudowany na bazie EagerPy. Wspiera natywnie środowiska takie jak PyTorch, TensorFlow oraz JAX²⁶.

²⁵ IBM, *Adversarial Robustness Toolbox*, GitHub, <https://github.com/Trusted-AI/adversarial-robustness-toolbox> (dostęp: 28.04.2026).

²⁶ Foolbox, dokumentacja, <https://foolbox.readthedocs.io/en/stable/modules/attacks.html> (dostęp: 28.04.2026).

FOOLBOX ATTACKS



Rysunek 2. Przedstawienie graficzne rodzajów ataków adversarialnych dostępnych w bibliotece Foolbox. Źródło: opracowanie własne na podstawie dokumentacji biblioteki Foolbox, <https://foolbox.readthedocs.io> (dostęp: 28.04.2026).

Schemat ilustruje klasyfikację ataków adversarialnych dostępnych w bibliotece Foolbox. Wyróżniono trzy podstawowe podejścia: white-box, black-box oraz metody oparte na transformacjach wejścia.

Pierwsza grupa, czyli ataki typu white-box, umożliwia analizę wrażliwości modelu dzięki dostępowi do gradientów, co pozwala na generowanie przykładów adversarialnych (np. FGSM, PGD)²⁷.

Druga grupa obejmuje ataki typu black-box. Bazują one na interakcjach wejście–wyjście modelu, bez znajomości jego architektury ani gradientów. W tym podejściu model traktowany jest jako „czarna skrzynka”. Przykładem jest Boundary Attack, który polega na wysyłaniu zapytań do modelu oraz analizie jego odpowiedzi.

²⁷ Foolbox, dokumentacja, <https://foolbox.readthedocs.io/en/stable/modules/attacks.html> (dostęp: 28.04.2026).

Trzecia grupa obejmuje metody oparte na transformacjach wejścia, polegające na modyfikacji obrazu, takich jak dodawanie szumu lub rozmycie. Metody te nie wykorzystują informacji o modelu, w tym jego architektury ani gradientów.

Analiza struktury przedstawionego schematu pozwala na wyodrębnienie kluczowych funkcji narzędzia Foolbox, rozszerzonych o wnioski z przeprowadzonych eksperymentów.

Biblioteka Foolbox zapewnia implementację ataków gradientowych (white-box) oraz bezgradientowych (black-box). Obsługuje różne metryki odległości, w tym L_0 , L_1 , L_2 oraz L_∞ , umożliwiające ocenę wielkości perturbacji. Foolbox umożliwia ocenę, czy dana próbka ma charakter adversarialny, z wykorzystaniem m.in. kryteriów Misclassification, Top-k Misclassification oraz Targeted Misclassification. Ataki dostępne w Foolbox, w celu wyznaczenia minimalnej perturbacji, wykorzystują wewnętrzną optymalizację parametrów. Wśród nich znajdują się m.in. Gradient Sign Attack (FGSM), DeepFool Attack oraz L-BFGS Attack.

Uwzględniając przedstawione funkcje, można również wskazać zalety i wady narzędzia Foolbox, uzupełnione o wnioski z analizy literatury i własnych obserwacji.

Zalety	Wady
Bardzo wysoka wydajność w porównaniu do bardziej zasobożernych frameworków.	Koncentracja na atakach evasion, ograniczone wsparcie dla poisoning i extraction.
Narzędzie oferuje łatwą integrację z istniejącym środowiskiem testowym.	Ograniczone wbudowane funkcje generowania mechanizmów obronnych w porównaniu do IBM Adversarial Robustness Toolbox (ART).
Wsparcie dla standardowych benchmarków do porównywania odporności modeli.	Brak dedykowanych funkcji w zakresie bezpieczeństwa i zgodności - standardowe środowisko Python.

Tabela 2. Zalety i wady Foolbox²⁸.

²⁸ *Top 10 Adversarial Robustness Testing Tools*, <https://www.scmgalaxy.com/tutorials/top-10-adversarial-robustness-testing-tools-features-pros-cons-comparison/> (dostęp: 28.04.2026).

4. Podstawy teoretyczne

4.1 Czym jest ML (Machine Learning) i DL (Deep Learning)

Uczenie maszynowe (ang. Machine Learning, ML) to dziedzina sztucznej inteligencji, która pozwala na analizę dużych zbiorów danych oraz formułowanie wniosków na ich podstawie. Modele uczą się na podstawie danych, co umożliwia im identyfikowanie zależności oraz wykonywanie zadań takich jak klasyfikacja czy predykcja²⁹. Proces ten nie wymaga ręcznego definiowania reguł przez programistę³⁰.

Przykładem może być system autonomicznego pojazdu, który zapewnia pasażerowi bezpieczną podróż oraz adaptuje swoje działanie do zmieniających się warunków otoczenia.

Głębokie uczenie (ang. Deep Learning, DL) stanowi poddziedzinę uczenia maszynowego³¹ oraz jeden z dynamicznie rozwijających się obszarów sztucznej inteligencji. Wykorzystuje wielowarstwowe sieci neuronowe w celu uzyskiwania lepszych wyników w analizie danych³².

Celem tych systemów jest wykonywanie zadań typowych dla człowieka, takich jak rozpoznawanie obrazu czy tworzenie prognoz.

Rozwój deep learningu był możliwy m.in. dzięki zwiększeniu mocy obliczeniowej procesorów graficznych. Obecnie technologia ta znajduje zastosowanie w wielu dziedzinach, takich jak wykrywanie oszustw czy systemy transakcyjne.

4.2 Rodzaje modeli: konwolucyjne sieci neuronowe (CNN) oraz klasyczne modele uczenia maszynowego (drzewa decyzyjne)

Konwolucyjne sieci neuronowe (CNN) odgrywają istotną rolę w sztucznej inteligencji³³. Znajdują zastosowanie przede wszystkim w przetwarzaniu danych

²⁹ Trend Micro, *What is Machine Learning*, https://www.trendmicro.com/pl_pl/what-is/ai/machine-learning.html (dostęp: 28.04.2026).

³⁰ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, Wydawnictwo Naukowe PWN, Warszawa 2018.

³¹ OVHcloud, *What is Deep Learning*, <https://www.ovhcloud.com/pl/learn/what-is-deep-learning/> (dostęp: 28.04.2026).

³² SAS, *Deep Learning*, https://www.sas.com/pl_pl/insights/analytics/deep-learning.html (dostęp: 28.04.2026).

³³ Semcore, *CNN – konwolucyjne sieci neuronowe*, <https://semcore.pl/slownik/cnn-konwolucyjne-sieci-neuronowe/> (dostęp: 28.04.2026).

wizualnych oraz sygnałów³⁴, takich jak obrazy, nagrania wideo oraz dźwięk. Ich działanie opiera się na wykrywaniu wzorców w danych, co umożliwia ich analizę.

Zarówno uczenie maszynowe (ML), jak i uczenie głębokie (DL) wykorzystują dane do trenowania modeli bazujących na zależnościach matematycznych, które umożliwiają identyfikację wzorców oraz relacji w danych, a także predykcję wyników.

Modele uczenia maszynowego, takie jak drzewa decyzyjne, charakteryzują się stosunkowo niską złożonością oraz wyższą interpretowalnością wyników³⁵.

Uczenie głębokie cechuje się natomiast bardziej zaawansowaną strukturą oraz większymi zasobami obliczeniowymi³⁶.

4.3 Adwersarialne ataki na modele uczenia maszynowego: FGSM, PGD, CW

Zagrożenia dla systemów sztucznej inteligencji, takie jak ataki adwersarialne (*adversarial attacks*), zatrutowanie danych (*data poisoning*) oraz ekstrakcja modelu (*model extraction*), zostały przedstawione w rozdziale 1, w podrozdziale 1.3.

W niniejszym podrozdziale skoncentrowano się na wybranych aspektach technicznych tych zagrożeń, w zakresie niezbędnym do przeprowadzenia części eksperymentalnej pracy.

FGSM (Fast Gradient Sign Method) jest metodą polegającą na obliczeniu gradientu funkcji straty (*ang. loss*) względem danych wejściowych³⁷, a następnie wykorzystaniu jedynie znaku tego gradientu (*sign*). Na tej podstawie generowana jest perturbacja. W kolejnym etapie jest ona skalowana przy użyciu parametru ϵ (*epsilon*), a dalej dodawana do oryginalnego obrazu.

Cały ten proces prowadzi do pogorszenia jakości klasyfikacji modelu przy użyciu minimalnych zmian w danych wejściowych, jednocześnie podkreślając, że wartość funkcji straty ulega zwiększeniu.

PGD (Projected Gradient Descent), podobnie jak FGSM, korzysta z gradientu funkcji straty, lecz w przeciwieństwie do ataku jednoetapowego wykonuje wiele kolejnych

³⁴ Infoshare Academy, *Konwolucyjne sieci neuronowe*, <https://infoshareacademy.com/wiedza/konwolucyjne-sieci-neuronowe/> (dostęp: 28.04.2026).

³⁵ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, Wydawnictwo Naukowe PWN, Warszawa 2018.

³⁶ OVHcloud, *What is Deep Learning*, <https://www.ovhcloud.com/pl/learn/what-is-deep-learning/> (dostęp: 28.04.2026).

³⁷ Practical DevSecOps, *Fast Gradient Sign Method (FGSM)*, <https://www.practical-devsecops.com/glossary/fast-gradient-sign-method-fgsm/> (dostęp: 28.04.2026).

kroków. Proces rozpoczyna się od wykorzystania bazowych danych wejściowych lub ich niewielkich modyfikacji znajdujących się w ograniczeniu ϵ (epsilon).

W dalszym etapie następuje iteracyjna modyfikacja danych. Prowadzi to do zwiększenia błędu modelu, przy czym po każdej iteracji dane są sprowadzane z powrotem do dozwolonego zakresu perturbacji. W efekcie jakość modelu ulega pogorszeniu, co skutkuje obniżeniem dokładności klasyfikacji.

Oprócz ataków FGSM i PGD w literaturze można wyszczególnić również ataki typu CW (Carlini–Wagner). Twórcami tego ataku byli Nicolas Carlini oraz David Wagner. Jest on zaliczany do bardziej złożonych metod generowania przykładów adversarialnych³⁸. Jego celem jest optymalizacja perturbacji w taki sposób, aby prowadziła do błędnych klasyfikacji modelu.

4.4 White-box, black-box i gray-box

Wyróżnia się trzy scenariusze testowe w zależności od poziomu dostępu do systemu: white-box, black-box oraz gray-box.

White-box to podejście, w którym osoba testująca posiada pełny dostęp do struktury wewnętrznej systemu, jego logiki działania, dokumentacji oraz kodu źródłowego. Oferuje ono szeroki zakres testów, od działania aplikacji po dogłębną interpretację uzyskanych wyników. W związku z tym podejście to funkcjonuje również pod nazwą „full knowledge”.

Black-box to podejście przeciwstawne do white-box, w którym osoba testująca nie dysponuje wiedzą o wewnętrznej strukturze ani działaniu systemu³⁹. Podejście to porównuje się do „czarnej skrzynki”, która jedynie dostarcza wyników dla danych wejściowych, nie umożliwiając poznania przyczyn uzyskanych odpowiedzi. Osoba testująca opiera się wyłącznie na obserwowanych danych zewnętrznych. Black-box nosi też nazwę „zero-knowledge”.

Trzecie podejście, czyli gray-box, łączy elementy podejść black-box i white-box⁴⁰. Stanowi ono równowagę pomiędzy nimi. Osoba testująca posiada ograniczoną wiedzę na temat systemu.

³⁸ XLAB AI Security, *Carlini–Wagner Attack*, <https://xlabaisecurity.com/adversarial/cw/> (dostęp: 28.04.2026).

³⁹ Cognito, *Rodzaje testów penetracyjnych*, <https://www.cognito.pl/rodzaje-testow-penetracyjnych-black-box-white-box-grey-box> (dostęp: 28.04.2026).

⁴⁰ BezpiecznyKod, *White-box, black-box i gray-box*, <https://bezpiecznykod.pl/czym-jest-testowanie-white-box-black-box-i-gray-box/> (dostęp: 28.04.2026).

5. Implementacja

5.1 Środowisko implementacyjne (Python, PyTorch, IBM Adversarial Robustness Toolbox (ART), Foolbox)


Faza eksperymentalna rozpoczęła się od utworzenia środowiska wirtualnego *ai_test*. W tym celu wykorzystano narzędzie Anaconda Prompt (wersja 25.11.1) oraz język Python (wersja 3.10). W kolejnym etapie zainstalowano niezbędne komponenty, takie jak PyTorch, torchvision oraz IBM Adversarial Robustness Toolbox (ART)⁴¹. Kończącym etapem była instalacja Jupyter Notebook w celu weryfikacji poprawności działania wszystkich komponentów.

Szczegóły poszczególnych etapów przygotowania przedstawiono na rysunku 3.

```
(base) C:\Users\>conda create -n ai_test python=3.10
(base) C:\Users\>conda activate ai_test
(ai_test) C:\Users\>pip install torch torchvision
(ai_test) C:\Users\>pip install adversarial-robustness-toolbox
(ai_test) C:\Users\>pip install notebook
```

Rysunek 3. Utworzenie i aktywacja środowiska wirtualnego *ai_test* oraz instalacja bibliotek PyTorch, torchvision i IBM Adversarial Robustness Toolbox (ART); instalacja środowiska Jupyter Notebook w celu weryfikacji poprawności działania bibliotek.


W kolejnej fazie eksperymentu potwierdzono prawidłowe działanie zainstalowanych komponentów w środowisku *ai_test* (Rysunek 4-5). Biblioteki PyTorch oraz IBM Adversarial Robustness Toolbox (ART) zostały poddane weryfikacji.



Rysunek 4. Sprawdzenie działania biblioteki PyTorch w utworzonym środowisku *ai_test*.

Rezultat testu: biblioteka PyTorch działa poprawnie.

⁴¹ I. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples*, arXiv, 2015, <https://arxiv.org/abs/1412.6572> (dostęp: 28.04.2026).



Rysunek 5. Sprawdzenie działania IBM Adversarial Robustness Toolbox (ART) w stworzonym środowisku `ai_test`.

Rezultat testu: biblioteka ART działa poprawnie.

5.2 Model i dane

Procedura testowa obejmuje w dalszej kolejności stworzenie modelu sieci neuronowej, który będzie służył do klasyfikacji obrazów. W tym celu wykorzystano zbiór MNIST⁴².

Model zawiera również funkcję straty (*CrossEntropyLoss*), która mierzy różnicę między prawdziwymi cyframi a przewidywaniami modelu, oraz optymalizator (*ang. Adam optimizer*)^{43, 44}, który uczy model zapewniając ulepszenie wag sieci w trakcie treningu.

Następnie dane zostały skonwertowane do formatu NumPy, który jest niezbędny do uruchomienia biblioteki ART.

Listing 1. Implementacja modelu MNIST, przygotowanie danych testowych oraz konfiguracja klasyfikatora ART.

```
import torch.nn as nn

# prosty model CNN (jedna warstwa linearna dla MNIST)
model = nn.Sequential(
    nn.Flatten(),
```

⁴² A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks*, arXiv, 2018, <https://arxiv.org/abs/1706.06083> (dostęp: 28.04.2026).

⁴³ Y. Dong, Q.-A. Fu, X. Yang, T. Pang, H. Su, Z. Xiao, J. Zhu, *Benchmarking Adversarial Robustness*, arXiv, 2019, <https://arxiv.org/abs/1912.11852> (dostęp: 28.04.2026).

⁴⁴ EITCA Academy. *How does the Adam optimizer optimize the neural network model?*

<https://pl.eitca.org/artificial-intelligence/eitc-ai-dlhf-deep-learning-with-tensorflow/tensorflow/neural-network-model/examination-review-neural-network-model/how-does-the-adam-optimizer-optimize-the-neural-network-model/> (dostęp: 28.04.2026).

```

        nn.Linear(28*28, 10)
    )

    loss_fn = nn.CrossEntropyLoss()
    optimizer = torch.optim.Adam(model.parameters(), lr=0.01)

    # dummy dane testowe (10 obrazów 28x28)
    x_test = torch.rand((10, 1, 28, 28))
    y_test = torch.randint(0, 10, (10,))

    # konwersja na NumPy (ART wymaga)
    x_test_np = x_test.numpy()
    y_test_np = y_test.numpy()

    from art.estimators.classification import PyTorchClassifier

    classifier = PyTorchClassifier(model=model, loss=loss_fn, optimizer=optimizer,
                                   input_shape=(1, 28, 28), nb_classes=10)

```

Na bazie wcześniejszego utworzenia klasyfikatora przygotowano możliwość przeprowadzenia ataku FGSM.

5.3 Implementacja ataków FGSM

5.3.1 FGSM – IBM ART

```
[6]: from art.attacks.evasion import FastGradientMethod

attack = FastGradientMethod(estimator=classifier, eps=0.2)
x_test_adv = attack.generate(x=x_test_np)

print("FGSM wykonany, x_test_adv shape:", x_test_adv.shape)
FGSM wykonany, x_test_adv shape: (10, 1, 28, 28)
```

Rysunek 6. Przeprowadzono atak FGSM na opracowanych danych testowych.

Rezultat testu: zmienna `x_test_adv` zawiera zmodyfikowane obrazy o kształcie (10, 1, 28, 28).

5.3.2 FGSM – Foolbox

W kolejnym etapie wykorzystano narzędzie Foolbox⁴⁵ w celu przeprowadzenia ataku FGSM oraz oceny zachowania modelu. Aktywowano środowisko wirtualne `ai_test`, w którym zainstalowano bibliotekę Foolbox (wersja 3.20) oraz Jupyter Notebook w celu weryfikacji prawidłowego działania wszystkich komponentów. Szczegóły poszczególnych etapów przedstawiono na rysunkach 10-12.

```
Anaconda Prompt - jupyter n x + v
(base) C:\Users\>conda activate ai_test
```

Rysunek 7. Aktywowano środowisko wirtualne `ai_test`, które jest gotowe do instalacji biblioteki Foolbox w wersji 3.20.

```
(ai_test) C:\Users\>pip install foolbox==3.2.0
Collecting foolbox==3.2.0
  Downloading foolbox-3.2.0-py3-none-any.whl.metadata (6.5 kB)
Requirement already satisfied: numpy in .\miniconda3\envs\ai_test\lib\site
Requirement already satisfied: scipy in .\miniconda3\envs\ai_test\lib\site
Requirement already satisfied: setuptools in .\miniconda3\envs\ai_test\lib
Requirement already satisfied: eagerpy==0.29.0 in .\miniconda3\envs\ai_test
Requirement already satisfied: GitPython>=3.0.7 in .\miniconda3\envs\ai_test
Requirement already satisfied: typing-extensions>=3.7.4.1 in .\miniconda3\
Requirement already satisfied: requests>=2.24.0 in .\miniconda3\envs\ai_test
Requirement already satisfied: gitdb<5,>=4.0.1 in .\miniconda3\envs\ai_test
Requirement already satisfied: smmap<0,>=3.0.1 in .\miniconda3\envs\ai_test
Requirement already satisfied: charset-normalizer<4,>=2 in .\miniconda3\en
3.4.6)
Requirement already satisfied: idna<4,>=2.5 in .\miniconda3\envs\ai_test\l
Requirement already satisfied: urllib3<3,>=1.26 in .\miniconda3\envs\ai_test
Requirement already satisfied: certifi>=2023.5.7 in .\miniconda3\envs\ai_test
25)
Downloading foolbox-3.2.0-py3-none-any.whl (1.7 MB)
Installing collected packages: foolbox
Successfully installed foolbox-3.2.0
```

Rysunek 8. Po aktywowaniu środowiska wirtualnego `ai_test` przystąpiono do instalacji biblioteki Foolbox w wersji 3.20.

⁴⁵ M. I. Nicolae, M. Sinn, S. Tran, A. Rawat, R. Chellappa, P. Treleaven, *Adversarial Robustness Toolbox v1.0.0*, arXiv, 2018, <https://arxiv.org/abs/1807.01069> (dostęp: 28.04.2026).


```
(ai_test) C:\Users\ >jupyter notebook
```

Rysunek 9. W aktywnym środowisku wirtualnym *ai_test* zainstalowano Jupyter Notebook, aby w nim sprawdzić poprawność działania biblioteki Foolbox.

Dalsza implementacja została przedstawiona na rysunkach 10-12.

Sprawdzenie działania bibliotek PyTorch, Foolbox, MNIST i Matplotlib w utworzonym środowisku *ai_test* wykazało ich poprawne działanie. W dalszym kroku utworzono model sieci neuronowej (Simple MNIST) dla obrazów MNIST oraz ustawiono go w tryb `eval()`, aby atak FGSM mógł zostać prawidłowo przeprowadzony. Następnie wczytano zbiór testowy MNIST, pobrano pierwszych 5 obrazków oraz etykiety, które im odpowiadają.

```
[15]: import torch
import torch.nn as nn
import torchvision.datasets as datasets
import torchvision.transforms as transforms
import foolbox as fb
import matplotlib.pyplot as plt

print("Biblioteki załadowane!")
Biblioteki załadowane!

[16]: class SimpleMNIST(nn.Module):
    def __init__(self):
        super().__init__()
        self.flatten = nn.Flatten()
        self.fc = nn.Linear(28*28, 10) # jedno ukrycie, bardzo prosty model

    def forward(self, x):
        x = self.flatten(x)
        return self.fc(x)

model = SimpleMNIST()
model.eval() # Bardzo ważne! Foolbox wymaga modelu w trybie ewaluacji

[16]: SimpleMNIST(
  (flatten): Flatten(start_dim=1, end_dim=-1)
  (fc): Linear(in_features=784, out_features=10, bias=True)
)

[17]: transform = transforms.ToTensor()
dataset = datasets.MNIST(root="./data", train=False, download=True, transform=transform)

# Pobranie pierwszych 5 obrazków
images = torch.stack([dataset[i][0] for i in range(5)])
labels = torch.tensor([dataset[i][1] for i in range(5)])

print("Obrazki i etykiety wczytane!")
print("images.shape:", images.shape)
print("labels:", labels)

Obrazki i etykiety wczytane!
images.shape: torch.Size([5, 1, 28, 28])
labels: tensor([7, 2, 1, 0, 4])
```

Rysunek 10. Sprawdzenie środowiska, przygotowanie modelu oraz danych MNIST.

Utworzono opakowanie modelu (*wrapper*) w Foolbox (*fmodel*). Określono granice pikseli (0-10), aby atak FGSM mógł prawidłowo wyznaczać gradienty. W dalszej kolejności przeprowadzono atak FGSM z użyciem parametru `epsilon=0.3`, który określa maksymalną zmianę w pikselach obrazu. W kolejnym kroku przygotowano konwersję obrazów do formatu NumPy, ponieważ biblioteka Matplotlib wymaga danych w postaci *numpy.ndarray* w celu prawidłowego wyświetlenia.

```
[18]: fmodel = fb.PyTorchModel(model, bounds=(0,1))

[19]: attack = fb.attacks.FGSM()
adv_images_list = attack(fmodel, images, labels, epsilons=0.3) # zwraca listę
adv_images = adv_images_list[0] # wybieramy pierwszy (i jedyny) epsilon


print("Atak FGSM wykonany!")

Atak FGSM wykonany!

[20]: images_np = images.numpy()
adv_images_np = adv_images.numpy()
```

Rysunek 11. Przeprowadzenie ataku FGSM w bibliotece Foolbox oraz przygotowanie danych do przedstawienia efektów działania.

Dzięki temu możliwe było przedstawienie oryginalnych i adversarialnych obrazów w Jupyter Notebook. Wiersz górny przedstawia obrazy prawidłowe, natomiast wiersz dolny – obrazy po ataku FGSM.



Rysunek 12. Efekty działania ataku FGSM na obrazach testowych.

5.4 Procedura testowa

Przeprowadzenie ataku FGSM umożliwiło wizualizację zarówno oryginalnych, jak i adversarialnych obrazów. Proces ten jednoznacznie wykazał skuteczność perturbacji w kontekście obniżenia efektywności klasyfikacji modelu⁴⁶.

⁴⁶ J. Rauber, W. Brendel, M. Bethge, A. Gammernan, *Foolbox: A Python toolbox to benchmark the robustness of machine learning models*, arXiv, 2017, <https://arxiv.org/abs/1707.04131> (dostęp: 28.04.2026).

6. Wyniki

6.1 Tabela wyników: accuracy przed i po ataku, attack success rate

Po przeprowadzeniu ataku FGSM przy użyciu narzędzi IBM Adversarial Robustness Toolbox (ART) oraz Foolbox oceniono skuteczność modelu przed i po ataku.

W tym celu obliczono metryki:

- *accuracy* przed atakiem,
- *accuracy* po ataku,
- wskaźnik *Attack Success Rate (ASR)*, określający skuteczność przeprowadzonego ataku.

Następnie utworzono tabelę z wykorzystaniem biblioteki pandas.

Listing 2. Poniższy kod ma na celu stworzenie tabeli, przy czym metryki zostały wcześniej obliczone.

```
data = {  
    "Metryka": [  
        "Accuracy przed atakiem",  
        "Accuracy po ataku",  
        "Attack Success Rate (ASR)"  
    ],  
    "Wartość": [  
        accuracy_original,  
        accuracy_adv,  
        asr  
    ]  
}  
  
df = pd.DataFrame(data)  
df
```

```
[7]:
```

	Metryka	Wartość
0	Accuracy przed atakiem	0.2
1	Accuracy po ataku	0.0
2	Attack Success Rate (ASR)	0.2

```
[ ]:
```


Tabela 3. Rezultat skuteczności modelu przed i po ataku FGSM wraz ze wskaźnikiem *Attack Success Rate (ASR)*.

Wyniki jasno pokazują że model klasyfikował poprawnie 20% przypadków dla danych oryginalnych przed atakiem. Po przeprowadzeniu ataku FGSM sytuacja uległa diametralnej zmianie – *accuracy* spadło do 0%, co poskutkowało całkowicie błędnymi predykcjami modelu.

Wskaźnik *Attack Success Rate (ASR)* wyniósł 20%, co oznacza, że w 20% przykładów poprawnie sklasyfikowanych przed atakiem FGSM predykcje po ataku były błędne.

```
[11]: plt.bar(["Przed atakiem", "Po ataku ART", "Po ataku Foolbox"],
             [accuracy_original, accuracy_adv_art, accuracy_adv_fb])
plt.ylabel("Accuracy")
plt.title("Porównanie skuteczności modelu przed i po ataku FGSM")
plt.show()
```

Rysunek 13. Kod, który generuje wykres porównawczy *accuracy* modelu przed i po ataku przy użyciu narzędzi IBM Adversarial Robustness Toolbox (ART) oraz Foolbox.



Rysunek 14. Zestawienie skuteczności modelu przed i po ataku FGSM.

Na wykresie przedstawiono porównanie skuteczności modelu (*accuracy*) w trzech wariantach: przed atakiem oraz po zastosowaniu ataku FGSM przy użyciu 2 narzędzi. Do przeprowadzenia eksperymentu wykorzystano narzędzia IBM Adversarial Robustness Toolbox (ART) oraz Foolbox. Na osi poziomej przedstawiono trzy warianty: przed atakiem, po ataku IBM Adversarial Robustness Toolbox (ART) oraz po ataku Foolbox, natomiast oś pionowa przedstawia wartość *accuracy* oznaczającą odsetek sklasyfikowanych próbek.

Po zastosowaniu ataku adwersarialnego FGSM wartość *accuracy* spadła do 0% zarówno w przypadku IBM Adversarial Robustness Toolbox (ART), jak i Foolbox. Atak FGSM okazał się bardzo skuteczny w manipulacji modelem, co przełożyło się na błędną klasyfikację danych.




```
[58]: import pandas as pd

df = pd.DataFrame({
    "Atak": ["Brak", "FGSM ART", "PGD ART", "FGSM Foolbox", "PGD Foolbox"],
    "Accuracy (%)": [accuracy_clean, accuracy_fgsm_art, accuracy_pgd_art, accuracy_fgsm_fb, accuracy_pgd_fb]
})
# Zakończanie do 2 miejsc po przecinku
df["Accuracy (%)"] = df["Accuracy (%)"].round(2)

print(df)
```

Rysunek 15. Kod w Pythonie służący do wygenerowania tabeli przedstawiającej skuteczność ataków FGSM oraz PGD przy użyciu IBM Adversarial Robustness Toolbox (ART) i Foolbox.



	Atak	Accuracy (%)
0	Brak	8.33
1	FGSM ART	9.21
2	PGD ART	9.58
3	FGSM Foolbox	0.00
4	PGD Foolbox	0.00

Tabela 4. Tabela przedstawia wyliczone wartości *accuracy* podane w %.

W przypadku ataków FGSM i PGD przeprowadzonych przy użyciu Foolbox, wartość *accuracy* spadła do 0% po ataku, co świadczy o wysokiej skuteczności tych ataków w obniżaniu efektywności klasyfikacji modelu.

Natomiast sytuacja jest zgoła odmienna w przypadku ataków wykonywanych przez IBM Adversarial Robustness Toolbox (ART):

- FGSM ART - 9,21%,
- PGD ART - 9,58%.

W przypadku braku jakiegokolwiek ataku wynik modelu wyniósł 8,33%.

6.2 Analiza wyników

Z przeprowadzonych testów można zauważyć, iż model osiągnął bardzo niską skuteczność. W przypadku zbioru MNIST (10 klas) poziom losowego zgadywania wynosi około 10%, co oznacza, że uzyskana *accuracy* (dokładność) na poziomie około 8% wskazuje na działanie modelu poniżej tego poziomu lub na poziomie zbliżonym do losowego klasyfikatora.

Wynik na poziomie około 8% sugeruje, że model nie osiąga odpowiedniej skuteczności uczenia (co może być interpretowane jako *underfitting*)⁴⁷, co w konsekwencji ogranicza wiarygodność przeprowadzonych eksperymentów, a porównanie zastosowanych narzędzi nie jest w pełni możliwe.

6.3 Porównanie *accuracy* modelu przed i po ataku (ART i Foolbox)

Nie odnotowano znaczących zmian po zastosowaniu narzędzia IBM Adversarial Robustness Toolbox (ART), gdyż predykcje były w dużej mierze nieprawidłowe jeszcze przed przeprowadzeniem ataku adversarialnego.

Na szczególną uwagę zasługuje narzędzie Foolbox, w przypadku którego odnotowano zarówno spadek efektywności, jak i pogorszenie wyników modelu.

Jakość modelu bazowego jest istotna, ponieważ uniemożliwia jednoznaczną ocenę skuteczności narzędzia Foolbox oraz porównanie z IBM Adversarial Robustness Toolbox (ART).

Można zatem stwierdzić, że jakość modelu bazowego odgrywa istotną rolę w kontekście skuteczności ataków adversarialnych. Wyniki testów są zdecydowanie bardziej wiarygodne, gdy model jest odpowiednio wytrenowany, na bieżąco monitorowany oraz gdy wprowadza się nowe pomysły lub poddaje się go różnym wariantom testów.

Na podstawie artykułu naukowego *Explaining and Harnessing Adversarial Examples*⁴⁸ autorstwa Goodfellowa i współautorów zauważono, jak zachowują się modele uczenia maszynowego. Nie zawsze końcowy rezultat odpowiada oczekiwaniom,

⁴⁷ Multi-Future *Overfitting i underfitting – czym są i jak je rozpoznać*. <https://multi-future.pl/blog/czym-jest-overfitting-i-underfitting-jak> (dostęp: 28.04.2026).

⁴⁸ I. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples*, arXiv, 2015, <https://arxiv.org/abs/1412.6572> (dostęp: 28.04.2026).

jakie zakładano na początku. Modele są bardzo często podatne na generowanie błędnych odpowiedzi, zwłaszcza w trudnych lub nietypowych sytuacjach. Wprowadzona przez autorów metoda FGSM (Fast Gradient Sign Method) umożliwia generowanie przykładów adversarialnych, co pokazuje, że model nie zawsze „rozumie” dane, nawet jeśli są one prawidłowo oznakowane.

Dalsza analiza będzie się opierała na metodzie PGD opisanej przez m.in. Aleksandra Mądrygo i współautorów w 2018 roku⁴⁹, w celu poszerzenia informacji dotyczących skuteczniejszych ataków adversarialnych.

Na bazie artykułu naukowego *Towards Deep Learning Models Resistant to Adversarial Attacks* można zaobserwować istotne zjawisko w kontekście sieci neuronowej. Zauważono, że im model jest większy i ma bardziej rozbudowaną strukturę, tym jest bardziej uodporniony na ataki adversarialne, nawet jeśli jego trening opiera się wyłącznie na danych nieadwersarialnych.

Jeżeli model ma małą pojemność (jest „słaby”), to nie tylko będzie miał problemy ze skomplikowanymi klasyfikacjami, lecz także z obroną przed silnymi atakami, takimi jak PGD. Im mocniejszy atak, tym bardziej ogranicza się w przyswajaniu wiedzy. Aby zmniejszyć ryzyko, że inny model również zostanie zaatakowany, należy zarówno zwiększyć pojemność modelu, jak i wykorzystać podczas treningu silniejsze ataki.

PGD jest często określany jako atak pierwszego rzędu (*first-order adversary*). Jest to jeden z najsilniejszych ataków, który wykorzystuje lokalne informacje o sieci.

Istotny jest również odpowiedni trening sieci, który pozwala zwiększyć odporność na ataki adversarialne.

Warto podkreślić, że odporność modelu na ataki pierwszego rzędu przekłada się na zwiększenie jego odporności na ataki adversarialne.

W celu dokładniejszego przybliżenia wyników, poniżej przedstawiono wybrane wyniki zaczerpnięte z literatury, dotyczące dokładności modelu MNIST w zależności od rodzaju ataku adversarialnego.

⁴⁹ A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks*, arXiv, 2018, <https://arxiv.org/abs/1706.06083> (dostęp: 28.04.2026).

Method	Steps	Restarts	Source	Accuracy
Natural	-	-	-	98.8%
FGSM	-	-	A	95.6%
PGD	40	1	A	93.2%
PGD	100	1	A	91.8%
PGD	40	20	A	90.4%
PGD	100	20	A	89.3%
Targeted	40	1	A	92.7%
CW	40	1	A	94.0%
CW+	40	1	A	93.9%
FGSM	-	-	A'	96.8%
PGD	40	1	A'	96.0%
PGD	100	20	A'	95.7%
CW	40	1	A'	97.0%
CW+	40	1	A'	96.4%
FGSM	-	-	B	95.4%
PGD	40	1	B	96.4%
CW+	-	-	B	95.7%

Tabela 5. Wyniki dokładności poszczególnych modeli MNIST dla różnych rodzajów ataku adwersarialnego (wyniki zaczerpnięte z literatury naukowej).

Model MNIST, na którym nie przeprowadzono żadnego ataku, osiągnął dokładność 98,8%. FGSM, czyli prosty atak adwersarialny, spowodował niewielki spadek dokładności do około 95–96%. PGD doprowadził do największego spadku, osiągając około 90%. Zarówno ataki CW, jak i CW+ również obniżają skuteczność modelu, jednak nie są aż tak skuteczne jak atak PGD.

Wyniki zamieszczone w tabeli jasno pokazują, że w zależności od siły ataku wpływ na model jest różny. Rezultaty wskazują również, że ataki PGD należą do najsilniejszych i najskuteczniejszych, o czym świadczą dokładności poszczególnych modeli.

Aby lepiej zrozumieć skuteczność poszczególnych ataków i odporność modeli, dalsza analiza będzie oparta na wynikach benchmarku *Benchmarking Adversarial Robustness*⁵⁰ autorstwa m.in. Dong i in., 2019, co pozwoli uzyskać dokładniejsze wyniki.

CIFAR-10 [28]				ImageNet [48]			
Defense Model	Category	Intended Threat	Acc.	Defense Model	Category	Intended Threat	Acc.
Res-56 [22]	natural training	-	92.6	Inc-v3 [54]	natural training	-	78.0
PGD-AT [37]	robust training	ℓ_∞ ($\epsilon = 8/255$)	87.3	Ens-AT [56]	robust training	ℓ_∞ ($\epsilon = 16/255$)	73.5
DeepDefense [66]	robust training	ℓ_2	79.7	ALP [26]	robust training	ℓ_∞ ($\epsilon = 16/255$)	49.0
TRADES [68]	robust training	ℓ_∞ ($\epsilon = 8/255$)	84.9	FD [63]	robust training	ℓ_∞ ($\epsilon = 16/255$)	64.3
Convex [59]	(certified) robust training	ℓ_∞ ($\epsilon = 2/255$)	66.3	JPEG [18]	input transformation	General	77.3
JPEG [18]	input transformation	General	80.9	Bit-Red [65]	input transformation	General	61.8
RSE [35]	rand. & ensemble	ℓ_2	86.1	R&P [62]	(input) rand.	General	77.0
ADP [40]	ensemble	General	94.1	RandMix [69]	(certified input) rand.	General	52.4

Tabela 6. Efektywność poszczególnych modeli na zbiorach CIFAR-10 i ImageNet w zależności od zastosowanej obrony (wyniki zaczerpnięte z literatury naukowej).

Modele trenowane w sposób naturalny (natural training) osiągają najwyższą dokładność (*accuracy*) w przypadku braku ataku. Modele zaprojektowane z myślą o odporności, takie jak PGD-AT, TRADES czy DeepDefense (robust training), lepiej radzą sobie w konfrontacji z atakami, choć ich dokładność w normalnych warunkach jest nieco

⁵⁰ Y. Dong, Q.-A. Fu, X. Yang, T. Pang, H. Su, Z. Xiao, J. Zhu, *Benchmarking Adversarial Robustness*, arXiv, 2019, <https://arxiv.org/abs/1912.11852> (dostęp: 28.04.2026).

niższa. Inne metody obrony, np. JPEG (input transformation) czy ADP (ensemble), również zwiększają odporność, ale nie dają spektakularnych rezultatów. Warto podkreślić, że zarówno rodzaj modelu, jak i zastosowana metoda obrony mają wpływ na odporność na ataki adversarialne.

Na podstawie doświadczeń zdobytych podczas samodzielnych testów oraz analizy trzech artykułów naukowych można stwierdzić, że wytrenowanie modelu jest procesem czasochłonnym. Kluczowe znaczenie ma jakość modelu, w szczególności jego odporność na proste oraz bardziej zaawansowane ataki adversarialne. Na szczególne wyróżnienie zasługują dwa ataki – FGSM oraz PGD. FGSM, mimo swojej prostoty, może być skuteczny w przypadku słabszych modeli, natomiast PGD to jeden z najsilniejszych ataków, charakteryzujący się wysoką skutecznością. Jakość modelu odgrywa istotną rolę w kontekście odporności na ataki. Zarówno analiza benchmarku, jak i przeprowadzona procedura testowa wykazały, że lepiej wytrenowany model osiąga wyższą dokładność oraz pozwala na bardziej wiarygodną ocenę skuteczności ataków adversarialnych.

7. Analiza wyników

7.1 Ograniczenia eksperymentu

Uzyskane wyniki procedury eksperymentalnej należy traktować jako wstępne i orientacyjne. Narzędzia wymagają dalszego przeprowadzenia testów. Procedura testowa uwzględniała wyłącznie atak FGSM. Dalsze badania, obejmujące atak PGD przy użyciu narzędzi IBM Adversarial Robustness Toolbox (ART) oraz Foolbox, pozwoliłyby uzyskać bardziej szczegółowe wyniki. Celem eksperymentu było wykazanie różnic w efektywności. Testy przeprowadzono na PC z procesorem Intel i5, 32 GB RAM oraz GPU NVIDIA RTX 3070.

7.2 Interpretacja wyników i kontekst narzędzi

Według Nicolae i współautorów (2018) IBM Adversarial Robustness Toolbox (ART)⁵¹ ma szerokie zastosowanie. Jest przydatny nie tylko dla programistów, ale również w kontekście bezpieczeństwa systemów opartych na sztucznej inteligencji. ART jest biblioteką opartą głównie na języku Python i umożliwia korzystanie z różnych popularnych bibliotek i frameworków, takich jak TensorFlow, Keras, PyTorch, Scikit-learn, XGBoost, LightGBM czy CatBoost.

Ensemble Classifier to klasa, która scala kilka wytrenowanych klasyfikatorów w jeden zespół. Umożliwia to przeprowadzenie ataków adversarialnych na cały zespół modeli w tym samym czasie. W IBM Adversarial Robustness Toolbox (ART) wyróżnia się także *wrappery*, które pozwalają modyfikować działanie klasyfikatora. Szczególnie warto zwrócić uwagę na *Randomized Smoothing*, który zwiększa odporność modelu zarówno na zakłócenia (np. szumy Gaussa), jak i na ataki adversarialne.

Jonas Rauber w artykule *Foolbox: A Python toolbox to benchmark the robustness of machine learning models*⁵² omawia bibliotekę Foolbox. Jest to narzędzie oparte na języku programowania Python. Foolbox obsługuje m.in. frameworki takie jak PyTorch, Keras

⁵¹ M. I. Nicolae, M. Sinn, S. Tran, A. Rawat, R. Chellappa, P. Treleaven, *Adversarial Robustness Toolbox v1.0.0*, arXiv, 2018, <https://arxiv.org/abs/1807.01069> (dostęp: 28.04.2026).

⁵² J. Rauber, W. Brendel, M. Bethge, A. Gammernan, *Foolbox: A Python toolbox to benchmark the robustness of machine learning models*, arXiv, 2017, <https://arxiv.org/abs/1707.04131> (dostęp: 28.04.2026).

oraz TensorFlow. Dodatkowo narzędzie udostępnia interfejs API, który pozwala nie tylko testować różne metody ataków adversarialnych, lecz także je porównywać.

Na szczególną uwagę zasługuje fakt, że nawet zaawansowane modele uczenia maszynowego mogą popełniać błędy. Wynika to z faktu, że niewielkie zakłócenia (np. szumy) są praktycznie niezauważalne dla ludzkiego oka, a mimo to mogą prowadzić do błędnej klasyfikacji przez model, na przykład w przypadku obrazów. Dzięki możliwości znalezienia minimalnej perturbacji, wyniki są znacznie bardziej wiarygodne w ocenie odporności modelu.

7.3 Wnioski z eksperymentu i obserwacji

Na podstawie dotychczasowej analizy, można uwypuklić własne rekomendacje praktyczne dotyczące wykorzystania obu narzędzi.

Dla początkującego użytkownika lepszym wyborem będzie narzędzie Foolbox⁵³. Oferuje ono bardziej przystępne API, dzięki czemu łatwo korzystać się z biblioteki. Istotnym ułatwieniem dla osób z mniejszą wiedzą jest automatyczne dobieranie wartości konfiguracyjnych (hiperparametrów) ataku, co zmniejsza konieczność ręcznej konfiguracji.

W przeciwieństwie do Foolbox, IBM ART⁵⁴ jest rekomendowany dla użytkowników bardziej zaawansowanych, którzy chcą pracować z rozbudowanymi modelami, np. klasyfikatorami typu ensemble. Narzędzie wymaga większego doświadczenia w konfiguracji hiperparametrów, ale w zamian oferuje dodatkowe funkcje, takie jak *Randomized Smoothing* czy *Ensemble Classifier*.

ART jest również cenione w środowiskach biznesowych i przemysłowych ze względu na swoje możliwości w zakresie analizy odporności modeli oraz implementacji mechanizmów obrony przed atakami adversarialnymi.

⁵³ J. Rauber, W. Brendel, M. Bethge, A. Gammernan, *Foolbox: A Python toolbox to benchmark the robustness of machine learning models*, arXiv, 2017, <https://arxiv.org/abs/1707.04131> (dostęp: 28.04.2026).

⁵⁴ M. I. Nicolae, M. Sinn, S. Tran, A. Rawat, R. Chellappa, P. Treleaven, *Adversarial Robustness Toolbox v1.0.0*, arXiv, 2018, <https://arxiv.org/abs/1807.01069> (dostęp: 28.04.2026).

8. Rekomendacje używania narzędzi

8.1 Kiedy stosować ART, kiedy Foolbox

Grupą modeli, która stanowi jeden z głównych obiektów badań w kontekście ataków adwersarialnych, są modele oparte na konwolucyjnych sieciach neuronowych (*Convolutional Neural Networks*, CNN).

W przypadku prostszych modeli bardziej odpowiednim narzędziem do przeprowadzania testów jest Foolbox⁵⁵. Natomiast w przypadku bardziej rozbudowanych struktur oraz szerszej analizy modeli lepszym wyborem jest IBM Adversarial Robustness Toolbox (ART)⁵⁶.

Kolejnym istotnym aspektem jest konfiguracja ataków oraz sposób przeprowadzania testów, które wpływają na uzyskiwane wyniki. Z jednej strony Foolbox umożliwia szybkie testy przy wykorzystaniu niewielkiej liczby parametrów, natomiast z drugiej strony IBM Adversarial Robustness Toolbox (ART) zapewnia większą kontrolę nad całym procesem ataku, co pozwala uzyskać bardziej szczegółowe i dokładne wyniki analizy.

Można stwierdzić, że oba narzędzia mogą być wykorzystywane jednocześnie. Foolbox może być stosowany do wstępnej oceny odporności modelu, natomiast IBM Adversarial Robustness Toolbox (ART) ze względu na większe możliwości sprawdzi się lepiej w bardziej rozbudowanych analizach oraz testach wymagających zastosowania mechanizmów obronnych.

8.2 Tabela porównawcza narzędzi

W celu przedstawienia rekomendacji dotyczących wykorzystania narzędzi omówiono IBM Adversarial Robustness Toolbox (ART) oraz Foolbox.

Dla lepszej wizualizacji porównania przedstawiono zestawienie ich kluczowych cech w formie tabelarycznej.

⁵⁵ J. Rauber, W. Brendel, M. Bethge, A. Gammerman, *Foolbox: A Python toolbox to benchmark the robustness of machine learning models*, arXiv, 2017, <https://arxiv.org/abs/1707.04131> (dostęp: 28.04.2026).

⁵⁶ M. I. Nicolae, M. Sinn, S. Tran, A. Rawat, R. Chellappa, P. Treleaven, *Adversarial Robustness Toolbox v1.0.0*, arXiv, 2018, <https://arxiv.org/abs/1807.01069> (dostęp: 28.04.2026).

Narzędzie	Foolbox	IBM ART
Poziom trudności	niski	wysoki
Poziom zaawansowania użytkownika	początkujący	zaawansowany
API	przystępne, intuicyjne	bardziej rozbudowane
Konfiguracja ataków	prosta, częściowo automatyczna (dobieranie hiperparametrów)	ręczna, występuje wiele opcji konfiguracyjnych, mechanizmy typu <i>wrapper</i>
Obsługiwane modele	CNN, proste modele klasyfikacyjne	modele zespołowe (<i>ensemble</i>), złożone klasyfikatory
Obsługiwane frameworki	PyTorch, TensorFlow, Keras	PyTorch, TensorFlow, Keras, Scikit-learn i inne
Dodatkowe funkcje	wyszukiwanie minimalnej perturbacji	<i>Randomized Smoothing, Ensemble Classifier</i>
Zastosowanie	szybkie testy, benchmarking modeli	zastosowania biznesowe i przemysłowe, analiza odporności modeli

Tabela 7. Porównanie dotyczące wykorzystania narzędzi Foolbox oraz IBM Adversarial Robustness Toolbox (ART).

9. Wnioski

9.1 Podsumowanie wyników i obserwacji

W niniejszej pracy główny cel, jakim było porównanie narzędzi IBM Adversarial Robustness Toolbox (ART) oraz Foolbox, został zrealizowany. Przeprowadzone eksperymenty potwierdziły skuteczność procedury testowej. Wyniki wykazały, że atak PGD (iteracyjny) charakteryzuje się największą skutecznością w porównaniu do innych metod. Jednocześnie atak FGSM również stanowi istotne zagrożenie i powinien być uwzględniany w analizie bezpieczeństwa modeli. Przeprowadzone testy wykazały brak odporności analizowanych modeli na ataki adversarialne, co skutkowało częstymi błędami klasyfikacji oraz spadkiem ich skuteczności (*accuracy*).

9.2 Wnioski ogólne

Po wykorzystaniu obu narzędzi w trakcie przeprowadzonych testów można zaobserwować porównywalną skuteczność w zakresie oceny odporności modeli.

Należy jednak zwrócić uwagę na kwestie ich wszechstronności oraz konfigurowalności. Wybór narzędzia powinien uwzględniać nie tylko architekturę badanego modelu, ale również cel przeprowadzanej analizy, co ułatwia dopasowanie odpowiedniego rozwiązania.

Sztuczna inteligencja może stanowić istotne zagrożenie w przypadku jej nieodpowiedniego wykorzystania, a przykładem tego są ataki adversarialne. Istotnym aspektem badań był również wybór narzędzia, który wpływa na możliwości przeprowadzania testów i analizy odporności modeli. Przed zastosowaniem modeli w praktyce konieczne jest przeprowadzenie odpowiednich testów bezpieczeństwa, które pozwalają ocenić ich podatność na perturbacje danych wejściowych.

9.3 Ograniczenia i dalsze prace

Należy również zaznaczyć, że procedura eksperymentalna nie obejmowała wszystkich typów ataków ani modeli, co powinno być brane pod uwagę przy interpretacji wyników.

Rozszerzenie badań o większą liczbę scenariuszy mogłoby dostarczyć bardziej szczegółowych informacji na temat zachowania modeli sztucznej inteligencji w różnych warunkach.

10. Bibliografia

Literatura naukowa

1. I. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples*, arXiv, 2015, (dostęp: 28.04.2026).
2. A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu, *Towards Deep Learning Models Resistant to Adversarial Attacks*, arXiv, 2018, <https://arxiv.org/abs/1706.06083> (dostęp: 28.04.2026).
3. Y. Dong, Q.-A. Fu, X. Yang, T. Pang, H. Su, Z. Xiao, J. Zhu, *Benchmarking Adversarial Robustness*, arXiv, 2019, <https://arxiv.org/abs/1912.11852> (dostęp: 28.04.2026).
4. M. I. Nicolae, M. Sinn, S. Tran, A. Rawat, R. Chellappa, P. Treleaven, *Adversarial Robustness Toolbox v1.0.0*, arXiv, 2018, (dostęp: 28.04.2026).
5. J. Rauber, W. Brendel, M. Bethge, A. Gammernan, *Foolbox: A Python toolbox to benchmark the robustness of machine learning models*, arXiv, 2017, <https://arxiv.org/abs/1707.04131> (dostęp: 28.04.2026).

Książki

6. S. Russell, P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd ed., Pearson, 2009.
7. I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, Wydawnictwo Naukowe PWN, Warszawa 2018.

Dokumentacja i źródła techniczne

8. National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1, 2023, <https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf> (dostęp: 28.04.2026).
9. IBM, *Adversarial Robustness Toolbox*, <https://github.com/Trusted-AI/adversarial-robustness-toolbox> (dostęp: 28.04.2026).
10. Foolbox, *Dokumentacja*, <https://foolbox.readthedocs.io/en/stable/modules/attacks.html> (dostęp: 28.04.2026).

11. Practical DevSecOps, *Fast Gradient Sign Method (FGSM)*,
<https://www.practical-devsecops.com/glossary/fast-gradient-sign-method-fgsm/>
(dostęp: 28.04.2026).
12. XLAB AI Security, *Carlini–Wagner Attack*,
<https://xlabaisecurity.com/adversarial/cw/> (dostęp: 28.04.2026).
13. EITCA Academy, *How does the Adam optimizer optimize the neural network model?*, <https://pl.eitca.org/artificial-intelligence/eitc-ai-dltf-deep-learning-with-tensorflow/tensorflow/neural-network-model/examination-review-neural-network-model/how-does-the-adam-optimizer-optimize-the-neural-network-model/> (dostęp: 28.04.2026).

Artykuły i materiały internetowe

14. Trend Micro, *What is Machine Learning*,
https://www.trendmicro.com/pl_pl/what-is/ai/machine-learning.html (dostęp: 28.04.2026).
15. OVHcloud, *What is Deep Learning*, <https://www.ovhcloud.com/pl/learn/what-is-deep-learning/> (dostęp: 28.04.2026).
16. SAS, *Deep Learning*, https://www.sas.com/pl_pl/insights/analytics/deep-learning.html (dostęp: 28.04.2026).
17. Semcore, *CNN – konwolucyjne sieci neuronowe*, <https://semcore.pl/sloownik/cnn-konwolucyjne-sieci-neuronowe/>, (dostęp: 28.04.2026).
18. Infoshare Academy, *Konwolucyjne sieci neuronowe*,
<https://infoshareacademy.com/wiedza/konwolucyjne-sieci-neuronowe/> (dostęp: 28.04.2026).
19. Brian D. Colwell, *An Introduction to AI Model Extraction*,
<https://briandcolwell.com/an-introduction-to-ai-model-extraction/> (dostęp: 28.04.2026).
20. Top 10 Adversarial Robustness Testing Tools,
<https://www.scmgalaxy.com/tutorials/top-10-adversarial-robustness-testing-tools-features-pros-cons-comparison/> (dostęp: 28.04.2026).
21. Multi-Future, *Overfitting i underfitting – czym są i jak je rozpoznać*,
<https://multi-future.pl/blog/czym-jest-overfitting-i-underfitting-jak> (dostęp: 28.04.2026).

22. Infor.pl, *Test Turinga – sztuczna inteligencja*, <https://ai.infor.pl/sztuczna-inteligencja/5757751,test-turinga-ai.html> (dostęp: 28.04.2026).

Prawo i regulacje

23. Gov.pl, *Baza wiedzy – Zagrożenia dla systemów wykorzystujących AI*, <https://www.gov.pl/web/baza-wiedzy/zagrozenia-dla-systemow-wykorzystujacych-ai> (dostęp: 28.04.2026).
24. Gov.pl, *Projekt ustawy o AI*, <https://www.gov.pl/web/cyfryzacja/koniec-ery-nieuchwytnych-algorytmow--projekt-ustawy-o-systemach-sztucznej-inteligencji-przyjety-przez-rade-ministrow> (dostęp: 28.04.2026).
25. ISAP, *Ustawa o ochronie danych osobowych*, <https://isap.sejm.gov.pl/isap.nsf/DocDetails.xsp?id=WDU20150001480> (dostęp: 28.04.2026).
26. SIP Lex, *AI Act – Rozporządzenie UE 2024/1689*, <https://sip.lex.pl/akty-prawne/dzienniki-UE/rozporzadzenie-2024-1689-w-sprawie-ustanowienia-zharmonizowanych-przepisow-72359064> (dostęp: 28.04.2026).
27. Gov.pl, Ministerstwo Cyfryzacji, *Europejski AI Act opublikowany*, <https://www.gov.pl/web/cyfryzacja/europejski-ai-act-opublikowany> (dostęp: 28.04.2026).
28. PIBR, *Ustawa o biegłych rewidentach*, <https://www.pibr.org.pl/pl/aktualnosci/1801,Tekst-jednolity-ustawy-o-bieglych-rewidentach> (dostęp: 28.04.2026).
29. Prawo.pl, *Audyt wewnętrzny może być przeprowadzony przez audytora*, <https://www.prawo.pl/samorzad/audyt-wewnetrzny-moze-byc-przeprowadzony-przez-audytora,108951.html> (dostęp: 28.04.2026).

Źródła uzupełniające

30. BezpiecznyKod, *White-box, black-box i gray-box*, <https://bezpiecznykod.pl/czym-jest-testowanie-white-box-black-box-i-gray-box/> (dostęp: 28.04.2026).
31. Cognity, *Rodzaje testów penetracyjnych*, <https://www.cognity.pl/rodzaje-testow-penetracyjnych-black-box-white-box-grey-box> (dostęp: 28.04.2026).

11. Spisy

11.1 Spis rysunków

Rysunek 1. Wizualizacja zastosowania narzędzia IBM Adversarial Robustness Toolbox (ART) w kontekście współpracy zespołów Red Team i Blue Team	11
Rysunek 2. Przedstawienie graficzne rodzajów ataków adversarialnych dostępnych w bibliotece Foolbox	13
Rysunek 3. Utworzenie i aktywacja środowiska wirtualnego ai_test oraz instalacja bibliotek PyTorch, torchvision i IBM Adversarial Robustness Toolbox (ART); instalacja środowiska Jupyter Notebook w celu weryfikacji poprawności działania bibliotek	18
Rysunek 4. Sprawdzenie działania biblioteki PyTorch w utworzonym środowisku ai_test	18
Rysunek 5. Sprawdzenie działania IBM Adversarial Robustness Toolbox (ART) w stworzonym środowisku ai_test	19
Rysunek 6. Przeprowadzono atak FGSM na opracowanych danych testowych	21
Rysunek 7. Aktywowano środowisko wirtualne ai_test, które jest gotowe do instalacji biblioteki Foolbox w wersji 3.20	21
Rysunek 8. Po aktywowaniu środowiska wirtualnego ai_test przystąpiono do instalacji biblioteki Foolbox w wersji 3.20	21
Rysunek 9. W aktywnym środowisku wirtualnym ai_test zainstalowano Jupyter Notebook, aby w nim sprawdzić poprawność działania biblioteki Foolbox	22
Rysunek 10. Sprawdzenie środowiska, przygotowanie modelu oraz danych MNIST	22
Rysunek 11. Przeprowadzenie ataku FGSM w bibliotece Foolbox oraz przygotowanie danych do przedstawienia efektów działania	23
Rysunek 12. Efekty działania ataku FGSM na obrazach testowych	23
Rysunek 13. Kod, który generuje wykres porównawczy accuracy modelu przed i po ataku przy użyciu narzędzi IBM Adversarial Robustness Toolbox (ART) oraz Foolbox	25
Rysunek 14. Zestawienie skuteczności modelu przed i po ataku FGSM	25

Rysunek 15. Kod w Pythonie służący do wygenerowania tabeli przedstawiającej skuteczność ataków FGSM oraz PGD przy użyciu IBM Adversarial Robustness Toolbox (ART) i Foolbox	26
---	----

11.2 Spis tabel

Tabela 1. Zalety i wady IBM Adversarial Robustness Toolbox (ART)	12
Tabela 2. Zalety i wady Foolbox	14
Tabela 3. Rezultat skuteczności modelu przed i po ataku FGSM wraz ze wskaźnikiem Attack Success Rate (ASR)	25
Tabela 4. Tabela przedstawia wyliczone wartości accuracy podane w %	26
Tabela 5. Wyniki dokładności poszczególnych modeli MNIST dla różnych rodzajów ataku adversarialnego	29
Tabela 6. Efektywność poszczególnych modeli na zbiorach CIFAR-10 i ImageNet w zależności od zastosowanej obrony	29
Tabela 7. Porównanie dotyczące wykorzystania narzędzi Foolbox oraz IBM Adversarial Robustness Toolbox (ART)	34

11.3 Spis listingów

Listing 1. Implementacja modelu MNIST, przygotowanie danych testowych oraz konfiguracja klasyfikatora ART	19
Listing 2. Poniższy kod ma na celu stworzenie tabeli, przy czym metryki zostały wcześniej obliczone	24